D09 · 실측 리포트

promptbench

Claude Haiku · Sonnet · Opus 5.5 × effort × 프롬프트 v1/v2 를 한국어 3개 업무로 재 본 첫 실측 — 기본값 선정 결과 · 비용 · 지연 · 채점자 교정과 한계

문서 버전	1.0
작성일	2026-10-22
작성자	김태민
문서 상태	실측 완료본

변경 이력

버전	일자	내용	작성자
1.0	2026-10-22	최초 작성 — 계획 C 실측 결과	김태민

목차

1. 한눈에 보기
2. 실측 개요
3. 업무별 결과 · 기본값 선정
4. 예상 대 실제 비용 · 성공 지표
5. 채점자 교정과 한계

핵심 메시지 — 가장 비싼 조합이 기본값이 되지는 않았다. 세 업무 중 둘(T1 · T3)에서 가장 저렴한 모델 Haiku 가 기본값이 됐고, 큰 모델(Sonnet · Opus)은 같은 품질에 비용이 16~40배였다. 큰 모델이 확실히 앞선 곳은 T2 정보 추출 하나다. 다만 모든 판정은 **공통 30건 기준 판정 — 확정에는 추가 표본 필요**하고, T3 은 채점자 교정 일치율이 80% 에 못 미쳐 **참고용**이다.

표기 원칙 — 이 문서의 수치는 모두 `promptbench report` 가 만든 리포트(`planning/results/report.md`)의 값이다. D01 · D08 의 목표치 는 여기서 실측 값으로 바뀌었고, 4장에서 목표치 대 실제를 나란히 둔다. 문서 간 참조는 공통 ID(`POL-nn` 정책 · `ADR-nn` 결정 · `CMD-nn` 명령 · 업무 `T1` ~ `T3`)로 한다.

1. 한눈에 보기

업무	기본값(사전 등록한 선정 규칙의 결과)	공통 30건 품질	1,000건당 비용	읽을 때
T1 문의 분류	**claude-haiku-5-5 · max · v2**	정확도 0.833	$0.2248	같은 모델 medium · v2 는 0.800 에 $0.1024 · 지연 p50 0.8초. 100건 곡선에서도 max 가 +5 점 앞선다
T2 정보 추출	**claude-opus-5-5 · low · v2**	micro F1 0.675	$3.7745	Sonnet · medium · v2 는 0.667 에 $1.8941. 두 값의 차는 0.008 인데 차의 95% 상한이 0.144 라 허용폭(0.03)을 넘어, 규칙은 Opus 를 골랐다
T3 요약	**claude-haiku-5-5 · high · v2** — 참고용	루브릭 통과율 0.767	$0.2990	Sonnet · medium · v2 도 0.767 에 $4.7280. 교정 일치율 63.3% 라 확정하지 않는다

- **프롬프트 v2 가 대체로 앞선다.** R1 의 Haiku 5개 effort 평균으로 T1 · T2 · T3 모두 v2 가 이겼다(T3 high 에서 0.433 → 0.767 이 가장 크다). 그래서 R2 의 큰 모델 조합은 v2 로만 돌렸다. 예외도 있다 — T3 max 는 v1 0.594 · v2 0.500 이고, 공통 30건의 T1 xhigh 도 v2 가 낮다.
- **Haiku `max` 는 업무에 따라 비싸고 느리다.** T2 · T3 에서 1,000건당 $0.65~2.22, 지연 p50 15~27초, 출력이 끝나기 전에 잘리는 요청이 있었다(공통 30건 중 T2 v2 8건 · T3 2건). 한도를 올려도(T2 8,192 · T3 16,384 토큰) 같았다. T1 에서만 이득이 있다.
- **비용은 장부 기준 $4.3709 로 $5 상한 안**이다. 다만 콘솔 청구와 약 $1 의 차이가 있다(4장) — 이 장부의 신뢰도 한계로 남는다.

2. 실측 개요

항목	내용
모델	claude-haiku-5-5 (effort low · medium · high · xhigh · max) · claude-sonnet-5-5 (low · medium) · claude-opus-5-5 (low)
프롬프트	v1(최소 지시) · v2(v1 + 정의 · 판단 기준 · 예시) — D08 3장
업무 · 데이터	T1 문의 분류 · T2 정보 추출: MASSIVE ko-KR(CC BY 4.0) · T3 요약: XL-Sum 한국어(CC BY-NC-SA 4.0, 포트폴리오 · 연구용)
표본	후보 모델 조합마다 공통 30건. Haiku 는 R1 에서 main 100건 · T3 만 공통 30건
채점	T1 · T2 는 정답 대조, T3 은 Sonnet 5.5 · high 채점자의 3항목 루브릭(사실 일치 · 포괄성 · 형식)
흐름	pilot → R1 → judge-R1 → R2 → judge-R2 → latency → calibrate → report. 과금 단계는 모두 plan → approve → run 을 거쳤다 (POL-03 · POL-04)
선정 규칙	사전 등록: 짝지은 부트스트랩 10,000회 · 95% · 시드 20261020 · 허용폭 δ T1 0.03 · T2 0.03 · T3 0.05. 최고 품질 조합(B) 과의 차의 상한이 δ 이하인 조합 중 가장 저렴한 것(POL-13)

3. 업무별 결과 · 기본값 선정

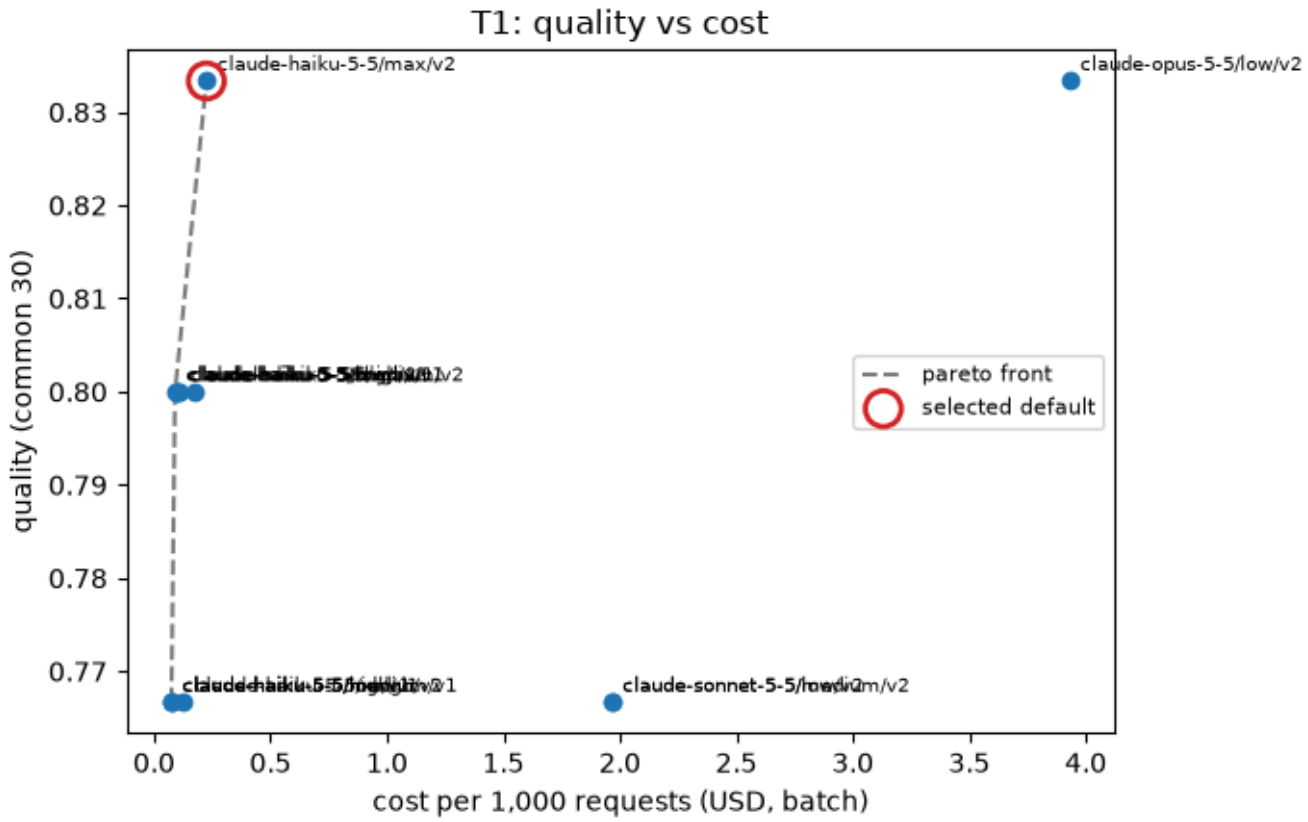
아래는 `promptbench report` 가 낸 리포트 본문 그대로다. 각주 · 열 정의 · 선정 규칙의 계산 값이 모두 들어 있다.

데이터 라이선스: T1 CC BY 4.0 https://huggingface.co/datasets/AmazonScience/massive · T2 CC BY 4.0 https://huggingface.co/datasets/AmazonScience/massive · T3 CC BY-NC-SA 4.0 (비영리 · 동일조건 — 포트폴리오 · 연구용으로만 사용, 원문 재배포 안 함, POL-15) https://huggingface.co/datasets/csebuetnlp/xlsum — 원본은 재배포하지 않는다.

T1 문의 분류

조합	채점 n	정확도 [95% CI]	1,000건당 비용[1]	지연 p50 / p90 (ms)	형식 오류	거절	잘림	배치 실패	B 대비 상한[2]	빠진 항목[3]
claude-haiku-5-5 · high · v1	30	0.767 [0.600, 0.900]	$0.0755	1162 / 1282	0	0	0	0	0.167	0
claude-haiku-5-5 · high · v2	30	0.800 [0.667, 0.933]	$0.1110	908 / 1455	0	0	0	0	0.100	0
claude-haiku-5-5 · low · v1	30	0.767 [0.600, 0.900]	$0.0745	1608 / 1644	0	0	0	0	0.167	0
claude-haiku-5-5 · low · v2	30	0.800 [0.667, 0.933]	$0.0982	1061 / 1430	0	0	0	0	0.100	0
claude-haiku-5-5 · max · v1	30	0.800 [0.667, 0.933]	$0.1749	1673 / 5488	0	0	0	0	0.100	0
claude-haiku-5-5 · max · v2	30	0.833 [0.700, 0.967]	$0.2248	3788 / 10178	0	0	0	0	B	0
claude-haiku-5-5 · medium · v1	30	0.767 [0.600, 0.900]	$0.0745	1312 / 1334	0	0	0	0	0.167	0
claude-haiku-5-5 · medium · v2	30	0.800 [0.667, 0.933]	$0.1024	847 / 903	0	0	0	0	0.100	0
claude-haiku-5-5 · xhigh · v1	30	0.800 [0.667, 0.933]	$0.0899	927 / 1324	0	0	0	0	0.100	0
claude-haiku-5-5 · xhigh · v2	30	0.767 [0.600, 0.900]	$0.1267	1957 / 3082	0	0	0	0	0.167	0
claude-opus-5-5 · low · v2	30	0.833 [0.700, 0.967]	$3.9295	1909 / 1987	0	0	0	0	0.100	0
claude-sonnet-5-5 · low · v2	30	0.767 [0.600, 0.900]	$1.9647	1035 / 1791	0	0	0	0	0.200	0
claude-sonnet-5-5 · medium · v2	30	0.767 [0.600, 0.900]	$1.9647	940 / 1686	0	0	0	0	0.200	0

[1] R1 · R2 후보 요청 전부(실패해 비용이 0 인 요청 포함)의 Batch 단가 비용 평균 × 1000. [2] 짝지은 부트스트랩 (B – C) 상한. 품질 · 채점 n 은 공통 30건 중 채점된 항목, 95% CI 는 단순 부트스트랩 분위. [3] B 와 둘 다 채점된 교집합에서 빠진 항목 수. B 행은 B 자신의 채점 불가 항목 수. 실패 유형 칸(형식 오류 · 거절 · 잘림 · 배치 실패)은 공통 30건의 R1 · R2 후보 요청만 센다 (R1 main 나머지 · 지연 측정은 제외).



기본값 선정 (δ = 0.03, 짝지은 부트스트랩 10000회 · 95% · seed 20261020)

- B(최고 품질): claude-haiku-5-5 · max · v2
- 동급(상한 ≤ δ): claude-haiku-5-5 · max · v2
- 기본값: **claude-haiku-5-5 · max · v2**

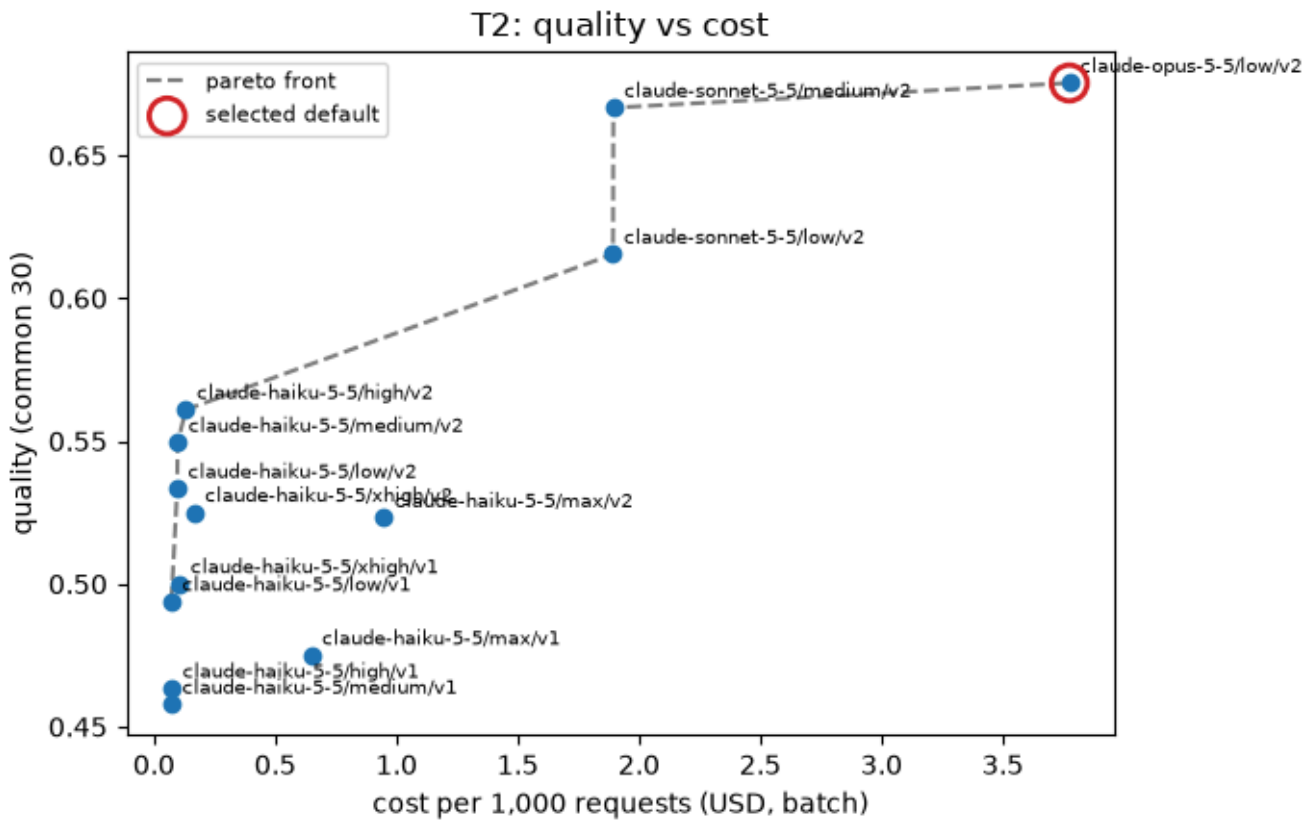
> 공통 30건 기준 판정 — 확정에는 추가 표본 필요

T2 정보 추출

조합	채점 n	필드 micro F1 [95% CI]	1,000건당 비용[1]	지연 p50 / p90 (ms)	형식 오류	거절	잘림	배치 실패	B 대비 상한[2]	빠진 항목[3]
claude-haiku-5-5 · high · v1	30	0.463 [0.289, 0.629]	$0.0733	968 / 1556	0	0	0	0	0.417	0
claude-haiku-5-5 · high · v2	30	0.561 [0.390, 0.719]	$0.1315	2291 / 2826	0	0	0	0	0.291	0
claude-haiku-5-5 · low · v1	30	0.494 [0.324, 0.652]	$0.0717	1478 / 1777	0	0	0	0	0.381	0

조합	채점 n	필드 micro F1 [95% CI]	1,000건당 비용[1]	지연 p50 / p90 (ms)	형식 오류	거절	잘림	배치 실패	B 대비 상한[2]	빠진 항목[3]
claude-haiku-5-5 · low · v2	30	0.533 [0.390, 0.667]	$0.0956	964 / 1139	0	0	0	0	0.310	0
claude-haiku-5-5 · max · v1	30	0.475 [0.308, 0.634]	$0.6481	15407 / 18894	0	0	1	0	0.375	0
claude-haiku-5-5 · max · v2	30	0.523 [0.340, 0.686]	$0.9473	27359 / 30478	0	0	8	0	0.308	0
claude-haiku-5-5 · medium · v1	30	0.458 [0.296, 0.615]	$0.0719	1336 / 1632	0	0	0	0	0.385	0
claude-haiku-5-5 · medium · v2	30	0.549 [0.405, 0.686]	$0.0974	912 / 1056	0	0	0	0	0.300	0
claude-haiku-5-5 · xhigh · v1	30	0.500 [0.333, 0.667]	$0.1060	869 / 1633	0	0	0	0	0.373	0
claude-haiku-5-5 · xhigh · v2	30	0.525 [0.364, 0.679]	$0.1651	2903 / 3356	0	0	0	0	0.331	0
claude-opus-5-5 · low · v2	30	0.675 [0.518, 0.822]	$3.7745	2099 / 2106	0	0	0	0	B	0
claude-sonnet-5-5 · low · v2	30	0.615 [0.462, 0.756]	$1.8927	1005 / 2445	0	0	0	0	0.215	0
claude-sonnet-5-5 · medium · v2	30	0.667 [0.522, 0.795]	$1.8941	1246 / 1303	0	0	0	0	0.144	0

[1] R1 · R2 후보 요청 전부(실패해 비용이 0 인 요청 포함)의 Batch 단가 비용 평균 × 1000. [2] 짝지은 부트스트랩 (B – C) 상한. 품질 · 채점 n 은 공통 30건 중 채점된 항목, 95% CI 는 단순 부트스트랩 분위. [3] B 와 둘 다 채점된 교집합에서 빠진 항목 수. B 행은 B 자신의 채점 불가 항목 수. 실패 유형 칸(형식 오류 · 거절 · 잘림 · 배치 실패)은 공통 30건의 R1 · R2 후보 요청만 센다 (R1 main 나머지 · 지연 측정은 제외).



기본값 선정 (δ = 0.03, 짝지은 부트스트랩 10000회 · 95% · seed 20261020)

- B(최고 품질): claude-opus-5-5 · low · v2
- 동급(상한 ≤ δ): claude-opus-5-5 · low · v2
- 기본값: **claude-opus-5-5 · low · v2**

> 공통 30건 기준 판정 — 확정에는 추가 표본 필요

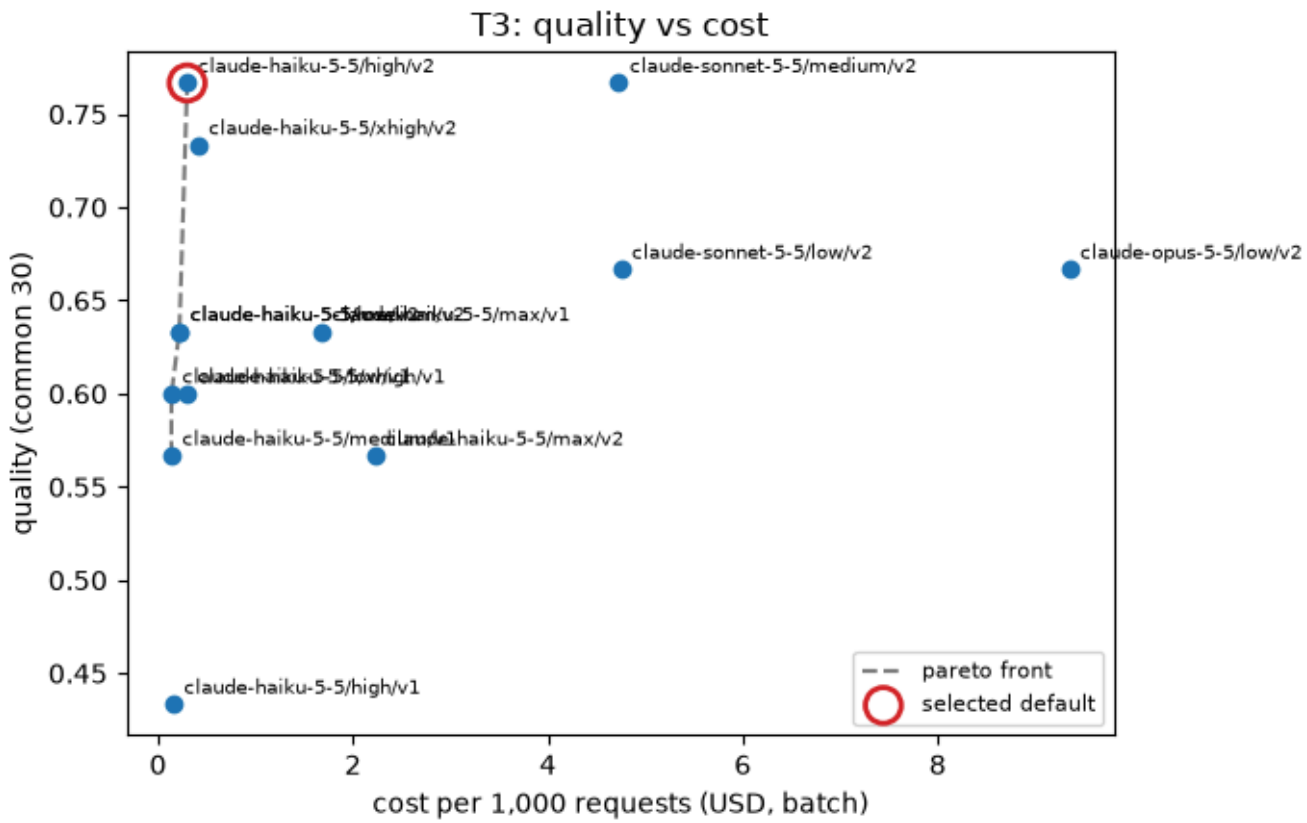
T3 요약

> **참고용** — 채점자 교정 일치율 63.3% 가 80% 미만이다 (POL-12). T3 결과를 확정된 사실로 읽지 않는다.

조합	채점 n	루브릭 통과율 [95% CI]	1,000건당 비용[1]	지연 p50 / p90 (ms)	형식 오류	거절	잘림	배치 실패	채점 불가	B 대비 상한[2]	빠진 항목[3]
claude-haiku-5-5 · high · v1	30	0.433 [0.267, 0.600]	$0.1554	1323 / 1813	0	0	0	0	0	0.500	0
claude-haiku-5-5 · high · v2	30	0.767 [0.600, 0.900]	$0.2990	3421 / 3970	0	0	0	0	0	B	0

조합	채점 n	루브릭 통과율 [95% CI]	1,000건당 비용[1]	지연 p50 / p90 (ms)	형식 오류	거절	잘림	배치 실패	채점 불가	B 대비 상한[2]	빠진 항목[3]
claude-haiku-5-5 · low · v1	30	0.600 [0.433, 0.767]	$0.1377	1547 / 1751	0	0	0	0	0	0.333	0
claude-haiku-5-5 · low · v2	30	0.633 [0.467, 0.800]	$0.2190	1215 / 1412	0	0	0	0	0	0.300	0
claude-haiku-5-5 · max · v1	30	0.633 [0.467, 0.800]	$1.6707	22307 / 22326	0	0	2	0	0	0.300	0
claude-haiku-5-5 · max · v2	30	0.567 [0.400, 0.733]	$2.2218	24005 / 59982	0	0	2	0	0	0.367	0
claude-haiku-5-5 · medium · v1	30	0.567 [0.400, 0.733]	$0.1372	2041 / 2078	0	0	0	0	0	0.400	0
claude-haiku-5-5 · medium · v2	30	0.633 [0.467, 0.800]	$0.2199	1388 / 1872	0	0	0	0	0	0.300	0
claude-haiku-5-5 · xhigh · v1	30	0.600 [0.433, 0.767]	$0.2906	5302 / 5489	0	0	0	0	0	0.367	0
claude-haiku-5-5 · xhigh · v2	30	0.733 [0.567, 0.867]	$0.4089	4709 / 5305	0	0	0	0	0	0.133	0
claude-opus-5-5 · low · v2	30	0.667 [0.500, 0.833]	$9.3507	3158 / 3375	0	0	0	0	0	0.267	0
claude-sonnet-5-5 · low · v2	30	0.667 [0.500, 0.833]	$4.7494	2424 / 3157	0	0	0	0	0	0.267	0
claude-sonnet-5-5 · medium · v2	30	0.767 [0.600, 0.900]	$4.7280	2174 / 2262	0	0	0	0	0	0.167	0

[1] R1 · R2 후보 요청 전부(실패해 비용이 0 인 요청 포함)의 Batch 단가 비용 평균 × 1000. [2] 짝지은 부트스트랩 (B – C) 상한. 품질 · 채점 n 은 공통 30건 중 채점된 항목, 95% CI 는 단순 부트스트랩 분위. [3] B 와 둘 다 채점된 교집합에서 빠진 항목 수. B 행은 B 자신의 채점 불가 항목 수. 실패 유형 칸(형식 오류 · 거절 · 잘림 · 배치 실패)은 공통 30건의 R1 · R2 후보 요청만 센다 (R1 main 나머지 · 지연 측정은 제외).



기본값 선정 (δ = 0.05, 짝지은 부트스트랩 10000회 · 95% · seed 20261020)

- B(최고 품질): claude-haiku-5-5 · high · v2
- 동급(상한 ≤ δ): claude-haiku-5-5 · high · v2
- 기본값: **claude-haiku-5-5 · high · v2**

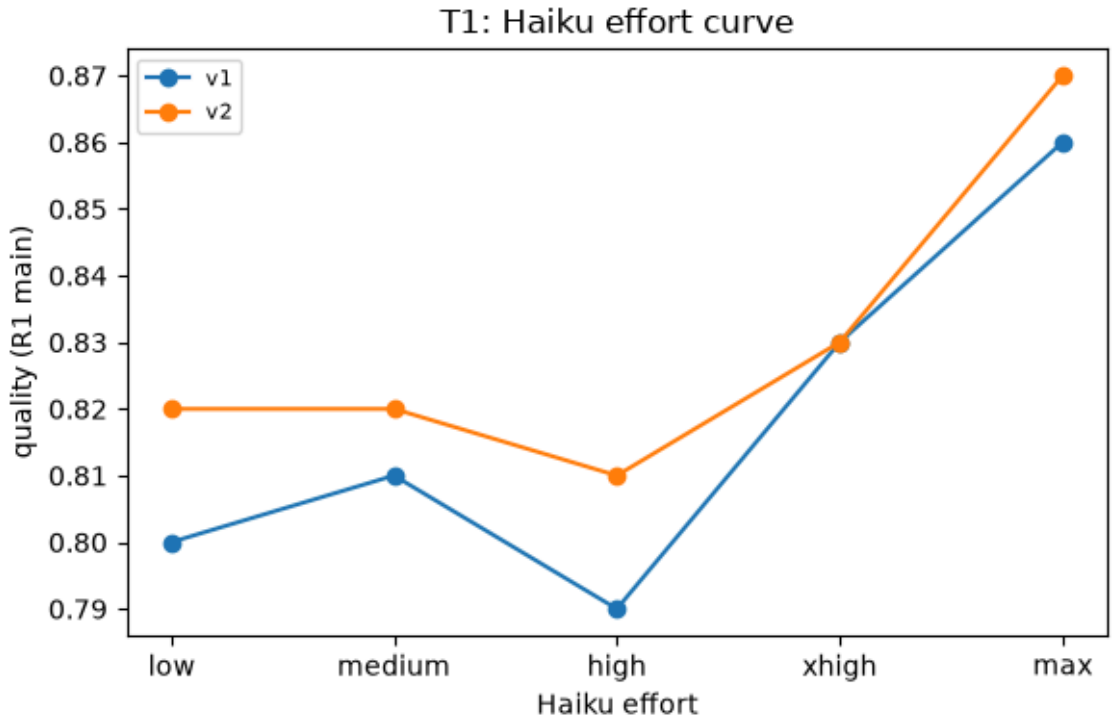
> 공통 30건 기준 판정 — 확정에는 추가 표본 필요

Haiku effort 곡선 (R1 main 전체)

T3 는 채점자가 공통 30건만 채점하므로 30건 기준이다.

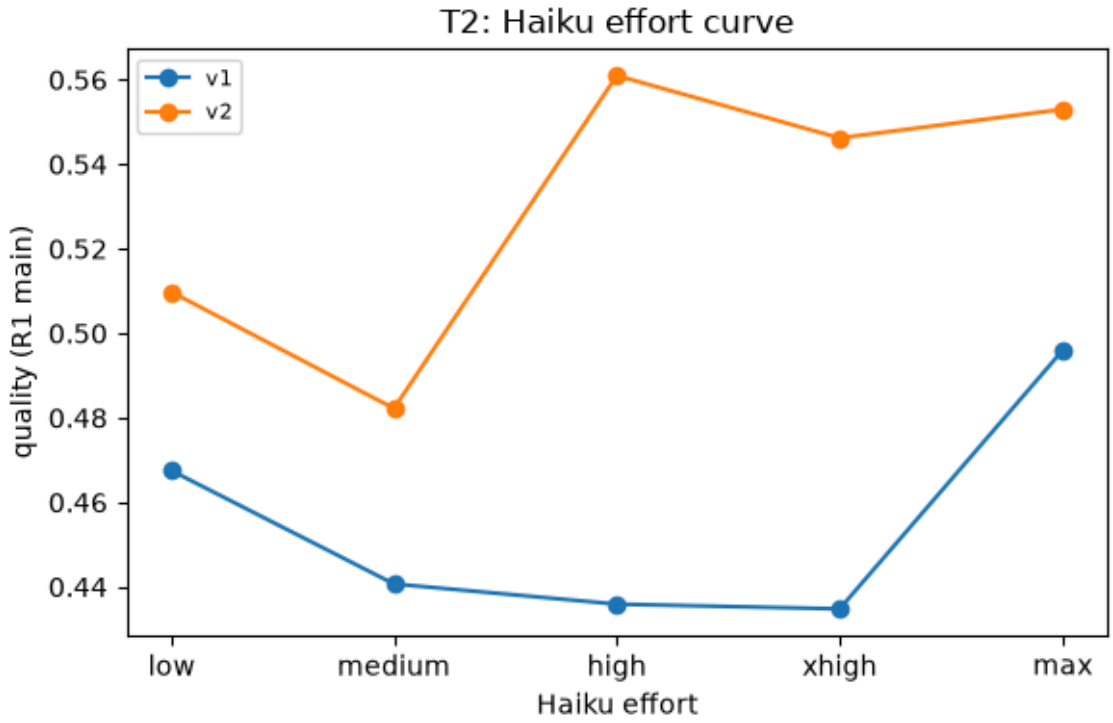
T1

effort	v1	v2
low	0.800 (n=100)	0.820 (n=100)
medium	0.810 (n=100)	0.820 (n=100)
high	0.790 (n=100)	0.810 (n=100)
xhigh	0.830 (n=100)	0.830 (n=100)
max	0.860 (n=100)	0.870 (n=100)



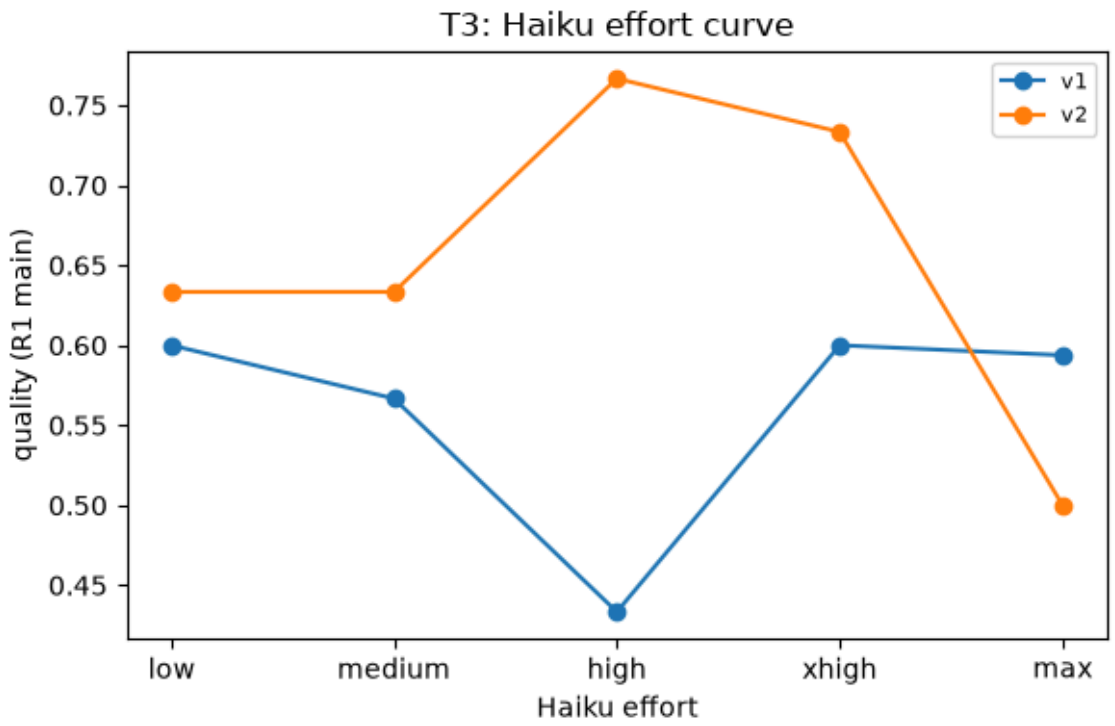
T2

effort	v1	v2
low	0.468 (n=100)	0.510 (n=100)
medium	0.441 (n=100)	0.482 (n=100)
high	0.436 (n=100)	0.561 (n=100)
xhigh	0.435 (n=100)	0.546 (n=100)
max	0.496 (n=100)	0.553 (n=100)



T3

effort	v1	v2
low	0.600 (n=30)	0.633 (n=30)
medium	0.567 (n=30)	0.633 (n=30)
high	0.433 (n=30)	0.767 (n=30)
xhigh	0.600 (n=30)	0.733 (n=30)
max	0.594 (n=32)	0.500 (n=34)



예상 대 실제 비용 (stage별)

stage	계획	상태	예상	보수	실제(장부)	예상 대비	보수 대비
pilot	pilot-0ec504d6	done	$1.0997	$1.0997	$0.0830	-92.5%	-92.5%
R1	R1-91232de6	done	$0.8454	$1.0554	$0.9320	+10.2%	-11.7%
judge-R1	judge-R1-d64d71ae	done	$1.6329	$1.9289	$1.5723	-3.7%	-18.5%
R2	R2-dfb0e783	done	$1.0672	$1.1046	$1.0275	-3.7%	-7.0%
judge-R2	judge-R2-84acb9d6	done	$0.4803	$0.6639	$0.5049	+5.1%	-24.0%
latency	latency-00a2b49b	done	$0.2516	$0.2990	$0.2513	-0.1%	-16.0%

오차가 커도 선정 규칙은 바뀌지 않고 다음 계획의 입력으로만 쓴다 (POL-06 · POL-13).

4. 예상 대 실제 비용 · 성공 지표

위 표(예상 대 실제 비용)가 단계별 값이다. 오차가 커도 선정 규칙은 바뀌지 않는다(POL-06 · POL-13).

#	지표	목표 목표치	실제	판정
M1	실측 총비용	$5 이하	장부 **$4.3709**. 콘솔 이번 달 지출은 latency 전 $5.12(장부 $4.1196) — 약 $1.00 차이는 원인을 확인하지 못했다	장부 기준 달성, 콘솔 기준은 확인 필요
M2	예상 대 실제 비용 오차	±30% 이내	파일럿 이후 5단계 −3.7% ~ +10.2%. 파일럿은 설계 단계 가정으로 예상해 −92.5%	달성(파일럿 제외)
M3	기본값 확정	업무 3개 모두	3개 선정. T3 은 참고용, 모두 공통 30건 기준	달성(단서 포함)
M4	승인 없는 과금 호출	0건	과금 계획 6개가 모두 사용자의 approve 뒤에 실행됐다. 장부 밖 호출(API 동작 확인 몇 건)이 있었다면 콘솔 차이의 일부일 수 있다	계획 기준 0건

- **장부와 콘솔의 차이.** 월 지출 한도($5)에 닿아 호출이 막혔을 때 콘솔은 $5.12, 장부는 $4.1196 이었다. 장부 밖 호출(승인 게이트 밖의 API 동작 확인), 같은 조직의 다른 사용, 비용 계산 차이가 후보다. 콘솔 청구 내역으로 날짜 · 모델별 대조를 하기 전에는 어느 쪽인지 말할 수 없다. 이 차이를 숨기지 않고 한계로 둔다.
- **월 지출 한도 사건.** latency 계획 중 count_tokens 가 한도로 400 을 냈다. 코드 문제가 아니었고 과금은 없었다. 사용자가 한도를 올려 해소했다. 도구는 장부 상한($5)만 알고 콘솔 한도는 모른다 — 다음 판의 개선점이다.

5. 채점자 교정과 한계

- 교정 30건: 일치율 63.3%, Cohen's κ 0.000
- 일치율이 80% 미만이라 T3 결과를 참고용으로 표시했다. 루브릭 개선을 한계로 남긴다.
- 채점자(Sonnet 5.5)가 Sonnet 후보의 요약도 채점하므로 자기 선호 편향 가능성이 있다 — 블라인드는 단서를 줄일 뿐 없애지 못한다.
- 채점자가 가장 강한 모델(Opus)이 아니다 — 교정 일치율이 그 영향을 확인하는 장치다.

교정 결과 해석. 사람이 교정 30건을 모두 3항목 통과로 채점해 사람 쪽에 변동이 없다. Cohen's κ 는 0 으로 퇴화해 신뢰도에 대한 정보가 없고, 일치율 63.3% 는 채점자가 불통과로 본 11건에서 나왔다. 그 11건 중 10건이 포괄성 항목이다. 포괄성은 참조 요약이 기사의 중심 사건을 담았다고 보고 비교하는데, 일부 참조 요약이 "BBC 코리아 보도" 같은 출처 안내라 비교 기준이 약했다. 채점자의 점수 보정은 하지 않았다.

한계

- **자기 선호 편향.** 채점자(Sonnet 5.5)가 Sonnet 후보의 요약도 채점한다. 블라인드는 단서를 줄일 뿐 없애지 못한다.
- **채점자가 가장 강한 모델이 아니다.** Opus 가 아니라 Sonnet 5.5 · high 를 쓴 것은 비용 때문이다(예산 결정). 교정 일치율이 그 영향을 확인하는 장치인데, 위처럼 퇴화해 확인하지 못했다.
- **MASSIVE 는 음성 비서 발화다.** 짧은 명령형 문장이라 기업 고객 문의와 길이 · 문체가 다르다. T1 · T2 의 절대 수치를 그대로 일반화하면 안 된다. 이 도구의 가치는 수치가 아니라 같은 절차로 자기 정답셋을 다시 돌릴 수 있다는 점이다(POL-15).
- **30건 표본.** 공통 표본이 30건이라 95% 구간이 넓고, 조합 사이 차이 대부분이 구간에 묻힌다. 기본값은 "이 표본에서 규칙이 고른 조합"이며 확정에는 추가 표본이 필요하다. 100건을 쓴 Haiku 내부 곡선만 더 정밀하다.
- **latency 는 조합마다 3건.** 동기 호출 평균이라 p90 은 표본이 너무 작다. Batch 와 달리 할인이 없고 서버 상태에 따라 달라진다.

- **XL-Sum 라이선스.** T3 은 CC BY-NC-SA 4.0 이라 포트폴리오 · 연구용으로만 쓴다. 기사 원문은 이 저장소에도 이 문서에도 싣지 않았다(POL-15).
- **장부와 콘솔의 약 $1 차이**는 4장 그대로 남는다.