D10 · 요약본

promptbench

"이 업무엔 이 조합이면 충분하다"를 비용과 함께 증명하는 Claude 기본값 결정 도구 — 기획 D01~D08 과 실측 D09 의 요약

문서 버전	1.0
작성일	2026-10-22
작성자	김태민
문서 상태	실측 완료본

변경 이력

버전	일자	내용	작성자
1.0	2026-10-22	최초 작성 — D01~D09 요약	김태민

1. 문제 정의

업무에 Claude 를 붙일 때 "어느 모델에, effort 는 얼마로, 프롬프트는 어떤 버전으로"를 정하는 근거가 없다. 기본값은 감이나 한두 건 시험으로 정해지고, 조합이 많아 손으로 다 돌릴 수 없으며, 평가 자체에도 돈이 든다. promptbench 는 업무별 정답셋으로 모델 × effort × 프롬프트 조합을 Message Batches API 에 돌려 정확도 · 비용 · 속도를 비교하고, 미리 정한 규칙으로 업무별 기본값을 고른다. 과금 호출 전에는 반드시 예상 비용을 보여 주고 승인을 받는다(D01).

2. MVP 범위

- **업무 3개**: T1 문의 분류 · T2 정보 추출(MASSIVE ko-KR) · T3 요약(XL-Sum 한국어), 업무별 프롬프트 v1 · v2 와 채점기.
- **비교 대상**: claude-haiku-5-5 · claude-sonnet-5-5 · claude-opus-5-5 × effort × 프롬프트 버전.
- **비용 통제**: `count_tokens` 예상 · 승인 게이트 · 누적 장부 · 상한 정지 · 가격표 확인일 경고.
- **입구**: CLI 하나, 명령 7개 — `prepare` · `plan` · `approve` · `run` · `status` · `calibrate` · `report` (CMD-01~CMD-07).
- **제외**: 다른 공급자 · 웹 UI · 프롬프트 자동 개선 · PyPI 배포(D01 6장).

3. 정책 요약

정책	내용
POL-01	실측 전체 예산 상한은 $5 — 실행 한 번이 아니라 프로젝트 누적 장부에 건다
POL-03 · POL-04	승인 전 과금 호출은 0건. 승인은 계획 해시에 묶이고 승인된 계획만 실행한다
POL-05 · POL-06	예상 · 보수 · 최악 3종 금액을 `count_tokens` 로 내고, 실제 비용과 나란히 보고한다
POL-13 · POL-14	선정 규칙과 허용폭 δ 는 실행 전에 사전 등록한다. 동급 후보 중 1,000건당 비용이 가장 낮은 조합을 고른다
POL-12 · POL-22	T3 채점자는 고정 · 블라인드. 사람 교정 일치율이 80% 미만이면 T3 결과는 참고용
POL-15 ~ POL-17	데이터 원본은 커밋하지 않고 라이선스를 기록한다. 키는 `ANTHROPIC_API_KEY` 하나만, 어디에도 남기지 않는다

4. 실측 결과 요약

사전 등록한 선정 규칙(짝지은 부트스트랩 10,000회 · 95% · 시드 20261020)이 업무별로 고른 기본값이다. 모든 판정은 **공통 30건 기준 판정 — 확정에는 추가 표본 필요**하다.

업무	기본값	품질(공통 30건)	1,000건당 비용	비고
T1 문의 분류	**claude-haiku-5-5 · max · v2**	정확도 0.833	$0.2248	—
T2 정보 추출	**claude-opus-5-5 · low · v2**	micro F1 0.675	$3.7745	—
T3 요약	**claude-haiku-5-5 · high · v2**	루브릭 통과율 0.767	$0.2990	참고용(교정 일치율 80% 미만)

- **비싼 모델이 늘 필요하지는 않았다.** T1 · T3 은 가장 저렴한 Haiku 가 기본값이 됐고, 큰 모델은 같은 품질에 비용이 16~40배였다. T2 정보 추출만 큰 모델(Opus)이 앞선다.
- **프롬프트 v2(정의 · 판단 기준 · 예시)가 대체로 앞선다.** R1 의 Haiku 5개 effort 평균으로 세 업무 모두 v2 가 이겼다.
- **Haiku `max` 는 T1 에서만 값을 한다.** T2 · T3 에서는 지연이 15~27초에 이르고 출력이 잘리는 요청이 있었다.
- **비용**: 장부 기준 총 $4.37(상한 $5). 단계별 예상 대 실제 오차는 파일럿 이후 −3.7% ~ +10.2% 였다. 콘솔 청구와는 약 $1 차이가 있고 원인은 확인하지 못했다(D09 4장).

5. 한계

- **T3 은 참고용**이다 — 채점자 교정 일치율 63.3%, 사람이 30건을 모두 통과로 채점해 Cohen's κ 가 0 으로 퇴화했다. 채점자는 가장 강한 모델이 아니고 Sonnet 후보를 채점하므로 자기 선호 편향 가능성이 남는다.
- **30건 표본** — 조합 사이 차이 대부분이 95% 구간에 묻힌다. 기본값은 이 표본에서 규칙이 고른 조합이다.
- **MASSIVE 는 음성 비서 발화**라 실제 고객 문의와 다르다. 이 도구의 가치는 수치가 아니라 같은 절차로 자기 정답셋을 다시 돌릴 수 있다는 점이다.
- **장부와 콘솔의 차이 · 월 지출 한도** — 도구는 장부 상한만 알고 콘솔 한도는 모른다.

문서 전체: D01 기획서 · D02 요구사항정의서 · D03 정책서 · D04 데이터·결과 규격서 · D05 IA·흐름도 · D06 CLI 화면 설계서 · D07 기능명세서 · D08 시스템·AI 설계서 · **D09 실측 리포트**(상세 수치).